CyberMind

Documentación del componente de IA

Documento final: problema, variables, modelos, modelo seleccionado y uso en la app

Equipo: David Escobar, Nicolás Sotelo y Juan Téllez · Noviembre de 2026

1. El problema que resuelve la IA

CyberMind es una aplicación para aprender ciberseguridad. Después de una evaluación diagnóstica de un tema (9 preguntas: 3 básicas, 3 intermedias y 3 avanzadas), el servicio de IA debe tomar una sola decisión para cada estudiante y cada tema:

- **REFUERZO:** el estudiante todavía necesita repasar antes de avanzar.
- **AVANCE:** el estudiante ya domina lo suficiente para pasar a la unidad siguiente.

1.1 Por qué es clasificación supervisada

Es un problema de clasificación porque la respuesta es una categoría (REFUERZO o AVANCE), no un número. Como solo hay dos categorías se llama clasificación binaria. Y es aprendizaje supervisado porque el modelo aprende de ejemplos que ya traen la respuesta correcta (la columna decision): ve miles de casos con sus resultados del diagnóstico y la decisión esperada, y aprende a reproducir esa decisión en casos nuevos.

1.2 Los datos

Como todavía no hay estudiantes reales, se usa un dataset sintético: 7.500 filas (1.500 estudiantes × 5 temas), generado por simulación con un modelo de teoría de respuesta al ítem. Cada fila es un par (estudiante, tema) con 8 variables de entrada y la decisión esperada. El 65,4 % de las filas es REFUERZO y el 34,6 % AVANCE, y el 5 % de las etiquetas se invirtió a propósito para simular desacuerdo entre evaluadores. Esto implica que ningún modelo puede acertar el 100 %: el techo teórico es cercano a 94,7 %.

1.3 Cómo se divide para probar

Los datos se dividen en 75 % para entrenar y 25 % para probar. El 75 % (5.625 filas, 1.125 estudiantes) es lo que el modelo usa para aprender; el 25 % (1.875 filas, 375 estudiantes) es un examen con casos que nunca vio. La división se hace por estudiante: un mismo estudiante nunca aparece en los dos grupos, para que el modelo no «copie» a alguien que ya conoce. Es la misma división para los cuatro modelos, por lo que la comparación es justa.

2. Justificación de las variables

El profesor pidió explicar por qué se eliminó una variable del dataset y por qué las demás sí son relevantes, es decir, si realmente le enseñan algo al modelo. Esta sección responde ambas cosas.

2.1 Variable eliminada: confianza autorreportada

Se eliminó porque no era necesaria para la decisión y agregaba ruido. Es una medida subjetiva: cada estudiante se califica con un criterio distinto, y quienes menos dominan un tema tienden a sobreestimar lo que saben (efecto Dunning-Kruger [Kruger y Dunning, 1999]). También se puede inflar a propósito para evitar el refuerzo, lo que abriría una forma de engañar a la app. La decisión debe apoyarse en lo que el estudiante demuestra, como propone el aprendizaje de dominio de Bloom, y eso ya lo mide el diagnóstico: solo con puntaje_tema el modelo alcanza 0,813 de exactitud en prueba, frente a 0,825 con las 8 variables. Por último, en un dataset sintético habría que inventar cómo se relaciona la confianza con el dominio real; ese supuesto no se puede validar sin datos de estudiantes, así que incluirla habría añadido una relación artificial en lugar de información.

2.2 Variables que se mantienen

Se evaluó cada una de las 8 variables de tres maneras, siempre con los datos sintéticos: (a) qué tan bien separa por sí sola REFUERZO de AVANCE; (b) cuánto empeora el modelo cuando esa variable se revuelve al azar (importancia por permutación, sobre los datos de prueba); y (c) cuánto cambia la exactitud si se quita la variable y se vuelve a entrenar.

Variable	Qué es	Qué muestran los datos	Veredicto
puntaje_tema	Porcentaje de aciertos del tema (de 0 a 100)	Es la que más separa las dos decisiones (0,84 en una escala donde 0,5 es azar y 1 es perfecto). Revolverla baja la exactitud del GBDT 12,8 puntos, mucho más que cualquier otra.	Esencial
aciertos_basico, aciertos_intermedio, aciertos_avanzado	Aciertos (0 a 3) en cada nivel de dificultad	Separan menos que el puntaje (0,70 / 0,79 / 0,74), y el puntaje del tema es exactamente la suma de ellas, así que repiten su información. Aun así, el nivel intermedio pesa mucho en la regresión logística (3,4 puntos al revolverlo) porque es el nivel de la unidad siguiente. El básico es el que menos aporta (0,1 a 0,3 puntos).	Útiles (intermedio y avanzado); el básico aporta muy poco
puntaje_global	Promedio del estudiante en los 5 temas	Es la segunda más importante en el GBDT (2,2 puntos). Aporta una visión de la habilidad general que ayuda cuando 9 preguntas son pocas para juzgar un tema.	Relevante
tema	Cuál de los 5 temas es	El porcentaje de REFUERZO cambia mucho entre temas: 49 % en ingeniería social, 77 % en criptografía. El mismo puntaje significa algo distinto según el tema.	Relevante
experiencia_previa	Ninguna, cursos o laboral	Gran diferencia entre grupos: 77 % de REFUERZO sin experiencia, 59 % con cursos y 43 % con experiencia laboral. En el modelo su aporte adicional es pequeño (0,3 a 0,8 puntos)	Relevante pero con aporte pequeño

Variable	Qué es	Qué muestran los datos	Veredicto
		porque el puntaje ya refleja gran parte de la experiencia.	
tiempo_promedio_seg	Tiempo medio por pregunta (segundos)	Separa poco por sí sola (0,63) y aporta 0,6 a 1,1 puntos. Su valor principal es detectar a quien responde muy rápido al azar, para no confiar en un puntaje que no es real.	Complementaria

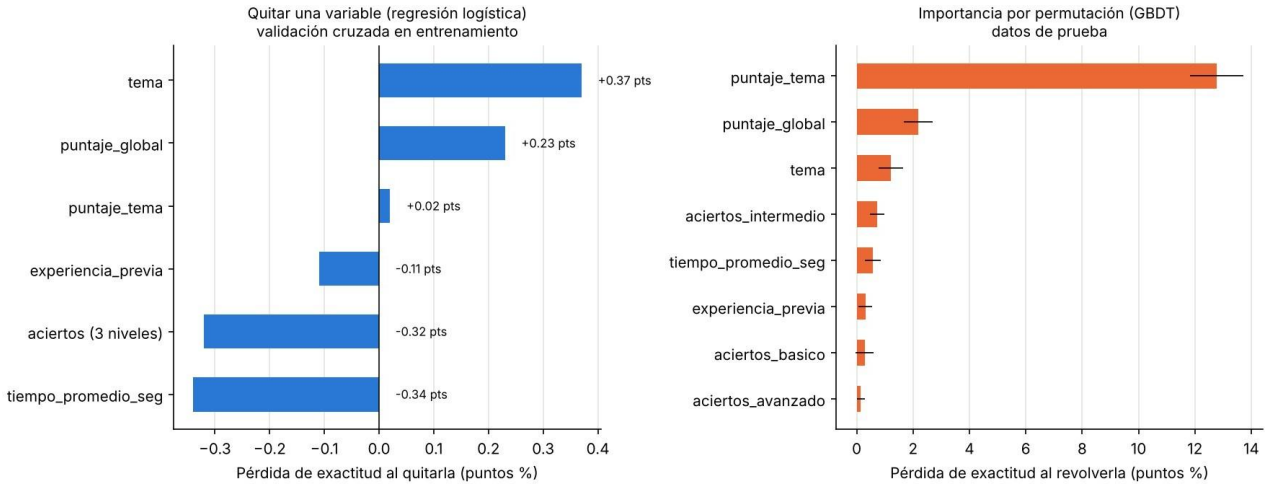


Figura 1. Izquierda: cambio de exactitud al quitar cada variable y reentrenar (valores negativos = el modelo no empeora, incluso mejora un poco). Derecha: cuánto empeora el GBDT al revolver cada variable.

2.3 Qué se concluye

- **Una variable domina:** puntaje_tema concentra casi toda la información. De hecho, una regresión logística que usa solo esa variable acierta el 81,3 % en prueba, frente al 82,5 % con las 8 variables.
- **Ninguna variable es indispensable por sí sola:** al quitar cualquiera de ellas, la exactitud cambia menos de medio punto (entre 80,4 % y 81,1 % en validación cruzada, frente a 80,8 % con todas), una diferencia dentro del ruido. Esto ocurre porque varias variables se solapan, por ejemplo el puntaje es la suma de los aciertos.
- **Las variables extra mejoran poco, pero tienen sentido:** tema, experiencia, puntaje global y tiempo añaden cerca de 1 punto en conjunto, y cada una responde a una razón del problema (dificultad distinta por tema, punto de partida del estudiante, habilidad general y confiabilidad de las respuestas).
- **Decisión sobre aciertos_basico:** es la que menos aporta (su importancia por permutación es la más baja y cercana a cero; no se probó quitarla sola, sino junto con los otros dos niveles). Se conserva por la simplicidad y coherencia del diagnóstico, que mide los tres niveles. Con estudiantes reales debe volver a medirse.

Advertencia importante: estas conclusiones valen para el dataset sintético. Que tema y experiencia influyan en la decisión viene en parte de cómo se generó el dataset. Con estudiantes reales la relevancia de cada variable debe volver a medirse.

3. Modelos de machine learning escogidos

Se probaron cuatro modelos de aprendizaje automático. Todos reciben las mismas 8 variables y la misma división 75 / 25, y se evaluaron primero con los datos de entrenamiento y después con los de prueba. Para el modelo de regla fija con un solo umbral (AVANCE si el puntaje del tema es 70 o más) se hizo una prueba aparte (acierta 81,3 % en prueba); no se incluye aquí porque no aprende de los datos.

Modelo	Cómo decide, en palabras simples	Ajustes
Árbol de decisión	Hace una serie de preguntas encadenadas («¿el puntaje es mayor a 72?», «¿el tiempo es menor a 19 s?») hasta llegar a una decisión. Se puede leer como un conjunto de reglas.	Profundidad máxima 4 y mínimo 50 casos por hoja, fijados a mano
Regresión logística	Da un peso a cada variable, los suma y los convierte en una probabilidad de REFUERZO. Si pasa de 50 %, decide REFUERZO. Los pesos muestran qué variables empujan hacia cada decisión.	Valores estándar de la librería (C = 1, regularización L2)
kNN (vecinos más cercanos)	Busca los 51 estudiantes más parecidos en el conjunto de entrenamiento y decide lo que decidió la mayoría de ellos.	Se buscó el mejor número de vecinos y tipo de distancia con validación cruzada: 51 vecinos, distancia Manhattan
GBDT (Gradient Boosting)	Combina 200 árboles pequeños, cada uno corrige los errores de los anteriores. Suele ser el más preciso, pero es el más difícil de explicar.	Búsqueda con validación cruzada: 200 árboles, profundidad 3, tasa de aprendizaje 0,05

4. Resultados por modelo

Cómo leer los números: la exactitud es el porcentaje de decisiones correctas (82,5 % significa que de cada 100 estudiantes, 82 o 83 reciben la decisión correcta). La precisión indica, de los que se mandaron a REFUERZO, cuántos realmente lo necesitaban. La sensibilidad indica, de los que realmente necesitaban refuerzo, a cuántos se detectó. F1 combina las dos. Los resultados de entrenamiento muestran qué tan bien responde el modelo a casos que ya vio; los de prueba, cómo responde a estudiantes nuevos, que es lo que importa.

4.1 Árbol de decisión (CART)

Métrica	Entrenamiento (75 %)	Prueba (25 %)	Diferencia (entreno − prueba)
Exactitud	81,4 %	81,8 %	−0,3 pts
Precisión (REFUERZO)	83,5 %	84,3 %	−0,8 pts
Sensibilidad (REFUERZO)	88,9 %	89,8 %	−0,9 pts
F1 (REFUERZO)	86,1 %	86,9 %	−0,8 pts

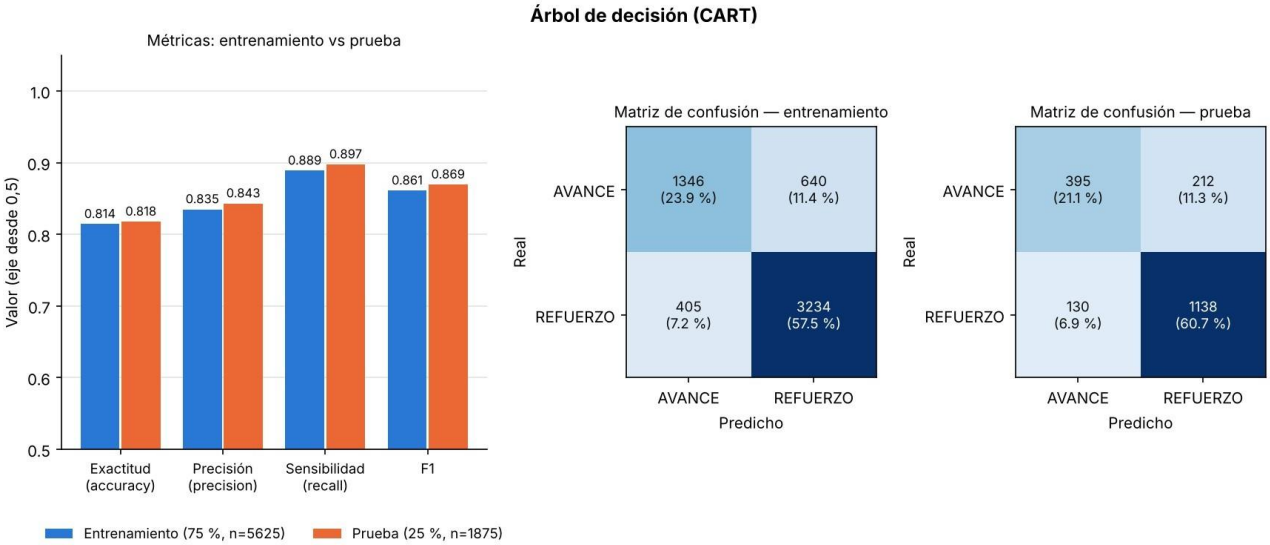


Figura 2. Ãrbol de decisión (CART): métricas y matrices de confusión, entrenamiento vs prueba.

Lectura. De 1.875 casos de prueba acertó 81,8 %. En prueba rinde igual o ligeramente mejor que en entrenamiento, por lo que no hay sobreajuste. Se equivocó de dos maneras: 130 veces mandó a AVANCE a alguien que necesitaba refuerzo (el error más costoso) y 212 veces mandó a REFUERZO a alguien que ya podía avanzar. La variable que más usa es puntaje_tema (89 % de su importancia). La regla principal es: si el puntaje del tema es de 72 o menos, REFUERZO; si es mayor, AVANCE, salvo en casos con puntaje global o tiempo bajos.

4.2 Regresión logística

Métrica	Entrenamiento (75 %)	Prueba (25 %)	Diferencia (entreno − prueba)
Exactitud	81,0 %	82,5 %	−1,5 pts
Precisión (REFUERZO)	83,4 %	85,0 %	−1,6 pts
Sensibilidad (REFUERZO)	88,0 %	89,9 %	−1,9 pts
F1 (REFUERZO)	85,7 %	87,4 %	−1,7 pts

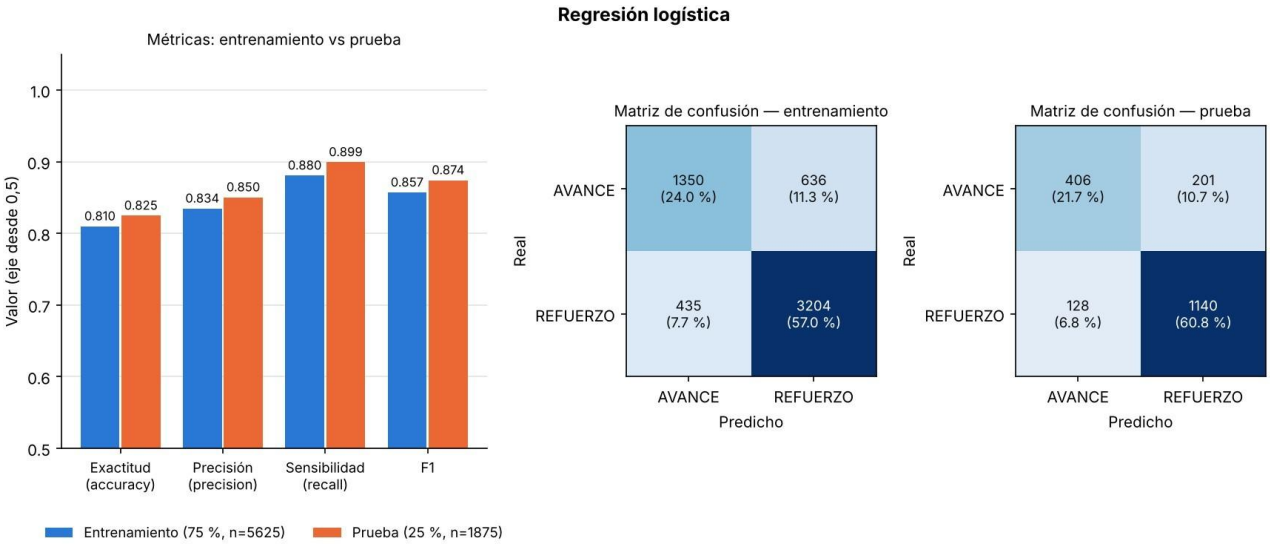


Figura 3. Regresión logística: métricas y matrices de confusión, entrenamiento vs prueba.

Lectura. De 1.875 casos de prueba acertó 82,5 %. En prueba rinde igual o ligeramente mejor que en entrenamiento, por lo que no hay sobreajuste. Se equivocó de dos maneras: 128 veces mandó a AVANCE a alguien que necesitaba refuerzo (el error más costoso) y 201 veces mandó a REFUERZO a alguien que ya podía avanzar. Los pesos más fuertes empujan hacia REFUERZO cuando el estudiante no tiene experiencia previa y en los temas de seguridad web y criptografía, y hacia AVANCE cuando acierta más en el nivel intermedio y en ingeniería social.

4.3 k vecinos más cercanos (kNN)

Métrica	Entrenamiento (75 %)	Prueba (25 %)	Diferencia (entreno − prueba)
Exactitud	82,3 %	83,0 %	−0,8 pts
Precisión (REFUERZO)	84,8 %	86,0 %	−1,2 pts
Sensibilidad (REFUERZO)	88,5 %	89,4 %	−0,9 pts
F1 (REFUERZO)	86,6 %	87,7 %	−1,1 pts

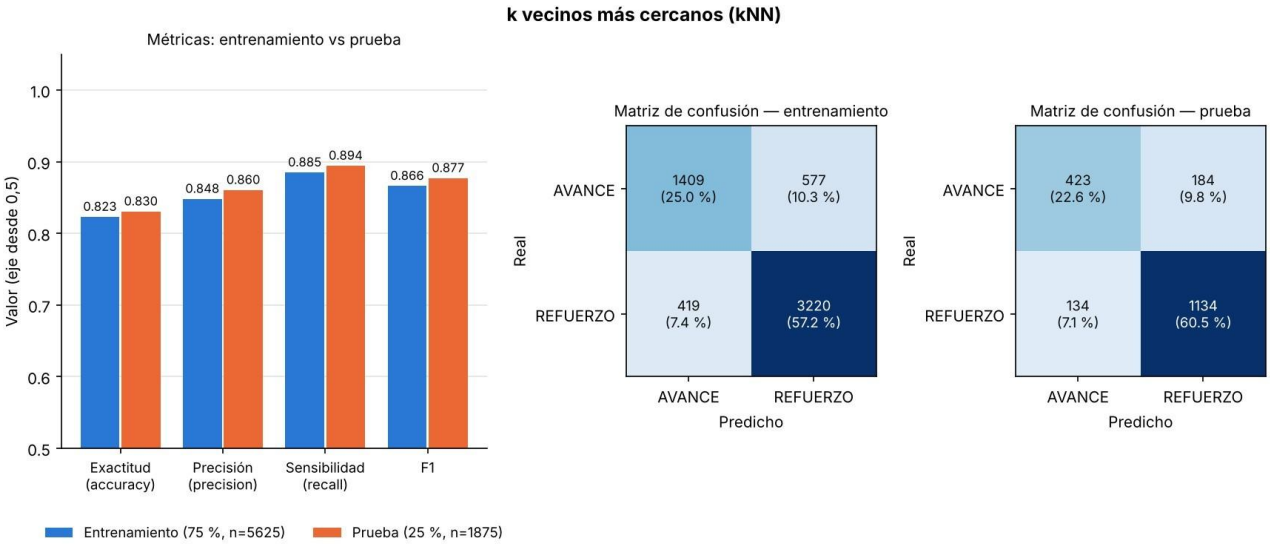


Figura 4. k vecinos más cercanos (kNN): métricas y matrices de confusión, entrenamiento vs prueba.

Lectura. De 1.875 casos de prueba acertó 83,0 %. En prueba rinde igual o ligeramente mejor que en entrenamiento, por lo que no hay sobreajuste. Se equivocó de dos maneras: 134 veces mandó a AVANCE a alguien que necesitaba refuerzo (el error más costoso) y 184 veces mandó a REFUERZO a alguien que ya podía avanzar. Se probaron 40 combinaciones de ajustes y la mejor (51 vecinos) logró 81,7 % en validación cruzada dentro del entrenamiento, consistente con el 83,0 % de prueba.

4.4 Gradient Boosting (GBDT)

Métrica	Entrenamiento (75 %)	Prueba (25 %)	Diferencia (entreno − prueba)
Exactitud	83,6 %	83,0 %	0,6 pts
Precisión (REFUERZO)	85,4 %	85,6 %	−0,2 pts
Sensibilidad (REFUERZO)	90,0 %	90,1 %	−0,0 pts
F1 (REFUERZO)	87,7 %	87,8 %	−0,1 pts

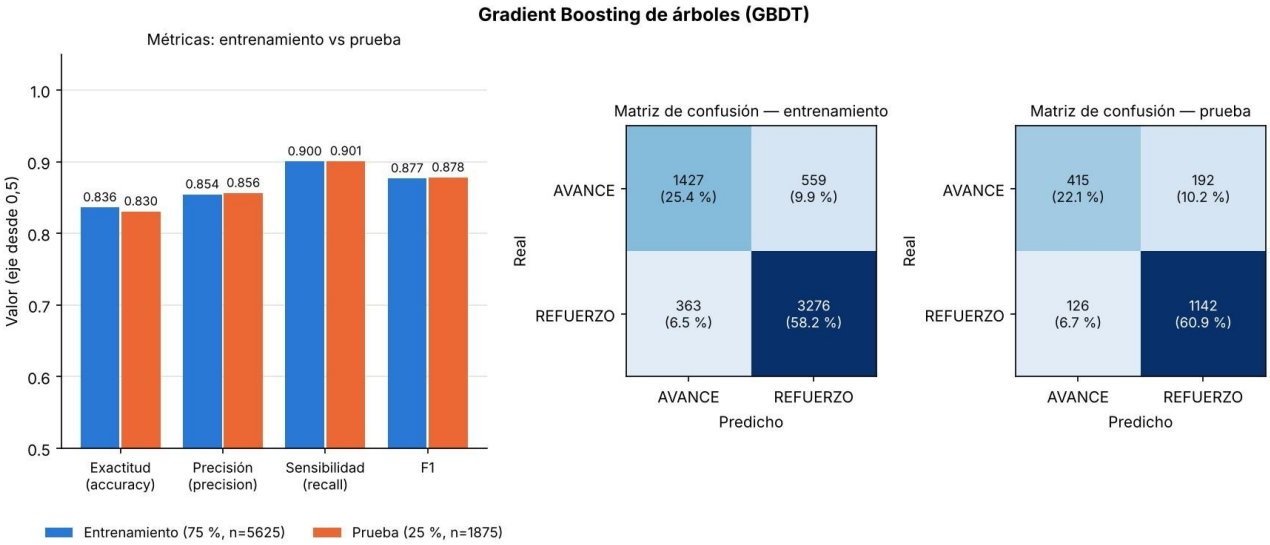


Figura 5. Gradient Boosting (GBDT): métricas y matrices de confusión, entrenamiento vs prueba.

Lectura. De 1.875 casos de prueba acertó 83,0 %. Rinde un poco mejor con lo que ya vio, pero la diferencia es pequeña, por lo que no hay sobreajuste. Se equivocó de dos maneras: 126 veces mandó a AVANCE a alguien que necesitaba refuerzo (el error más costoso) y 192 veces mandó a REFUERZO a alguien que ya podía avanzar. Se probaron 48 combinaciones de ajustes. Tiene la mayor exactitud de entrenamiento, pero en prueba queda igual que kNN. Usa sobre todo puntaje_tema (73 % de su importancia).

5. Comparativa entre los cuatro modelos

Modelo	Exactitud entrenamiento	Exactitud prueba	Diferencia	F1 prueba	Avanzar sin dominio (prueba)
Árbol de decisión (CART)	81,4 %	81,8 %	−0,3 pts	86,9 %	130
Regresión logística	81,0 %	82,5 %	−1,5 pts	87,4 %	128
k vecinos más cercanos (kNN)	82,3 %	83,0 %	−0,8 pts	87,7 %	134
Gradient Boosting (GBDT)	83,6 %	83,0 %	0,6 pts	87,8 %	126

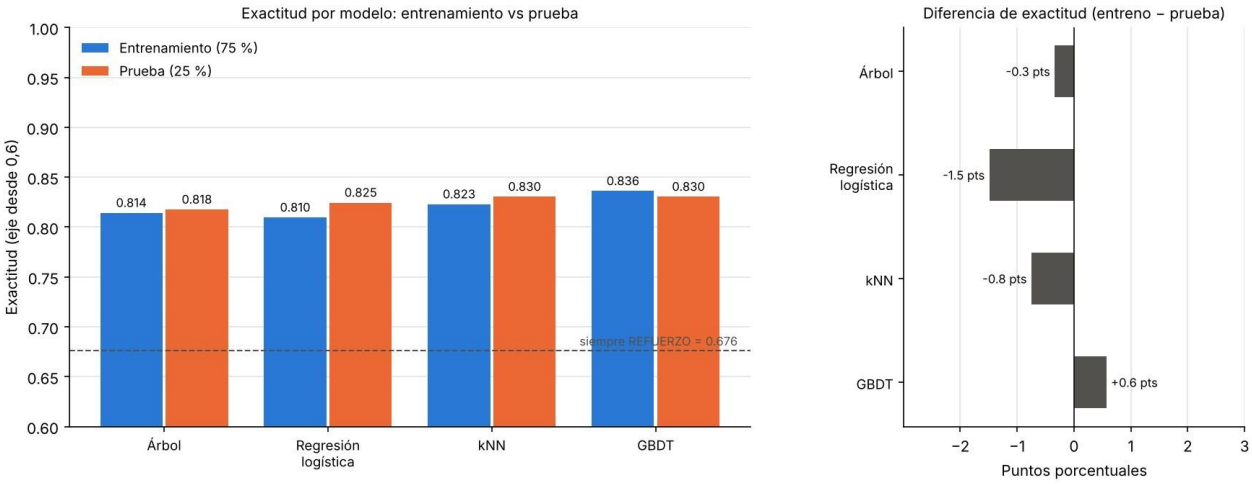


Figura 6. Exactitud de cada modelo con datos de entrenamiento y de prueba (izquierda) y diferencia entre ambas (derecha). La línea punteada es la exactitud de responder siempre REFUERZO.

5.1 Qué se observa

- **Ningún modelo está sobreajustado.** La exactitud de entrenamiento y la de prueba quedan a 1,5 puntos o menos en los cuatro. Un modelo que memoriza tendría un entrenamiento mucho más alto que su prueba.
- **En prueba sale igual o un poco mejor que en entrenamiento en tres de cuatro modelos.** No es un error: con una sola división, los estudiantes de prueba resultaron algo más fáciles de clasificar. La validación cruzada dentro del entrenamiento da cifras en el mismo rango (81,7 % en kNN y 81,9 % en GBDT).
- **Los cuatro rinden prácticamente igual.** En prueba van de 81,8 % a 83,0 %, una diferencia de 1,2 puntos, menor al margen de error de la medición (cerca de ±1,8 puntos). Con estos datos no se puede afirmar que uno sea mejor que otro por exactitud.
- **Todos superan con claridad la línea base.** Responder siempre REFUERZO acierta 67,6 % en prueba; los modelos aciertan entre 14 y 15 puntos más. Ninguno se acerca al techo teórico de 94,7 %: con solo 9 preguntas por tema y 5 % de ruido en las etiquetas, las variables no alcanzan para más.
- **El error más costoso se parece en todos.** Mandar a avanzar a quien necesitaba refuerzo ocurre entre 126 y 134 veces de 1.875 (alrededor del 7 %).

5.2 Cómo elegir entonces

Como la exactitud no desempata, la elección puede apoyarse en otros criterios del proyecto: qué tan fácil es explicar la decisión al estudiante y al docente (el árbol y la regresión logística son más explicables que kNN y GBDT), qué tan simple es mantener el modelo, y el costo del error de avanzar sin dominio.

5.3 Límites de estos resultados

- Todo se midió con datos sintéticos: valida que el método funciona sobre datos con la estructura esperada, no que vaya a rendir igual con estudiantes reales ni que mejore el aprendizaje.
- Las secciones 4 y 5 usan una sola división 75 / 25. Por eso, antes de elegir el modelo, la sección 6 repite la evaluación con 30 divisiones distintas.
- Solo kNN y GBDT tuvieron búsqueda de ajustes; el árbol y la regresión logística usaron valores fijados a mano, por lo que la comparación no es perfectamente pareja.

5.4 Archivos de apoyo

Los scripts de cada modelo (pruebas/fase1_comparacion_modelos/ y pruebas/fase2_entreno_vs_prueba/) y los notebooks de la carpeta notebooks/ reproducen todos los resultados de este documento. El análisis de variables está en docs/analisis_variables.json. Para todo se usó únicamente cybermind_sintetico.csv.

6. Modelo definitivo: GBDT

Con una sola división, los cuatro modelos quedan a 1,2 puntos de exactitud entre sí, dentro del margen de error. Para no elegir al azar se buscó un criterio que importe para la app y que destaque a un modelo de forma consistente.

6.1 El criterio: la calidad de la probabilidad

La app no recibe solo REFUERZO o AVANCE: recibe la probabilidad de REFUERZO, decide con ella (umbral 0,5) y la muestra junto a la decisión. Si la probabilidad es confiable, un 0,90 significa de verdad que 9 de cada 10 estudiantes en esa situación necesitan refuerzo, y el umbral se puede subir si se quiere ser más prudente. Por eso se compararon métricas que miden la probabilidad y no solo el acierto:

- **Log loss:** castiga las probabilidades muy seguras que resultan equivocadas. Menor es mejor.
- **AUC:** qué tan bien ordena a los estudiantes de mayor a menor riesgo de necesitar refuerzo. Mayor es mejor.
- **Brier:** error promedio entre la probabilidad y lo que realmente pasó. Menor es mejor.

6.2 Prueba con 30 divisiones

Se repitió 30 veces la división 75 / 25 por estudiante (semillas 100 a 129), con los mismos ajustes de la sección 4, y se contó qué modelo gana en cada división. Script: pruebas/fase3_seleccion_modelo/seleccion_modelo.py.

> **¿Y la regla fija del 70 %?** Acierta 81,3 % en prueba, muy cerca de los modelos, pero solo responde sí o no: no entrega una probabilidad ni permite subir el umbral. Por eso queda como regla de respaldo si el modelo no carga, y no como modelo principal.

Métrica (promedio de 30)	Árbol	Logística	kNN	GBDT	GBDT gana en
Log loss (menor = mejor)	0,431	0,443	0,443	**0,412**	**30 de 30**
AUC (mayor = mejor)	0,861	0,857	0,871	**0,874**	28 de 30
Brier (menor = mejor)	0,136	0,138	0,131	**0,129**	26 de 30
Avances sin dominio por división	152	136	139	**131**	16 de 30
Exactitud	0,806	0,814	0,819	0,820	17 de 30

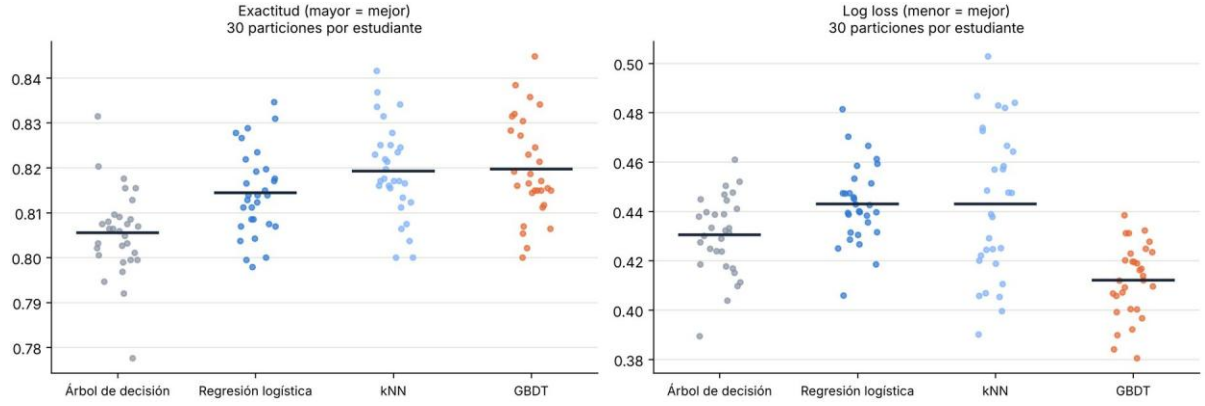


Figura 7. Exactitud (izquierda) y log loss (derecha) de cada modelo en las 30 divisiones. Cada punto es una división y la línea es el promedio. En exactitud kNN y GBDT se mezclan; en log loss GBDT queda por debajo de los demás.

6.3 Por qué GBDT

- **Sus probabilidades son las más confiables.** Gana en log loss en las 30 divisiones (0,412 frente a 0,431 del árbol y 0,443 de la regresión logística y de kNN).
- **También ordena y acierta mejor el riesgo.** Tiene el mejor AUC en 28 de 30 divisiones, el mejor Brier en 26 de 30 y el menor promedio de avances sin dominio (131 por división), que es el error más costoso.
- **La exactitud no fue el criterio.** En exactitud sigue empatado con kNN (0,820 frente a 0,819), por eso la elección se apoya en la probabilidad.
- **No sobreajusta.** La diferencia entre entrenamiento y prueba es de 0,6 puntos (sección 4.4).
- **Cabe en el celular.** Exportado ocupa unos 106 KB (sección 7). kNN, en cambio, necesita llevar consigo a todos los estudiantes de entrenamiento para comparar.

¿Y la regresión logística? Era la preferida al principio por ser la más fácil de explicar, pero no gana en ninguna métrica salvo en tamaño (2,8 KB). Como la app muestra la decisión junto con su probabilidad, se priorizó que esa probabilidad fuera la mejor.

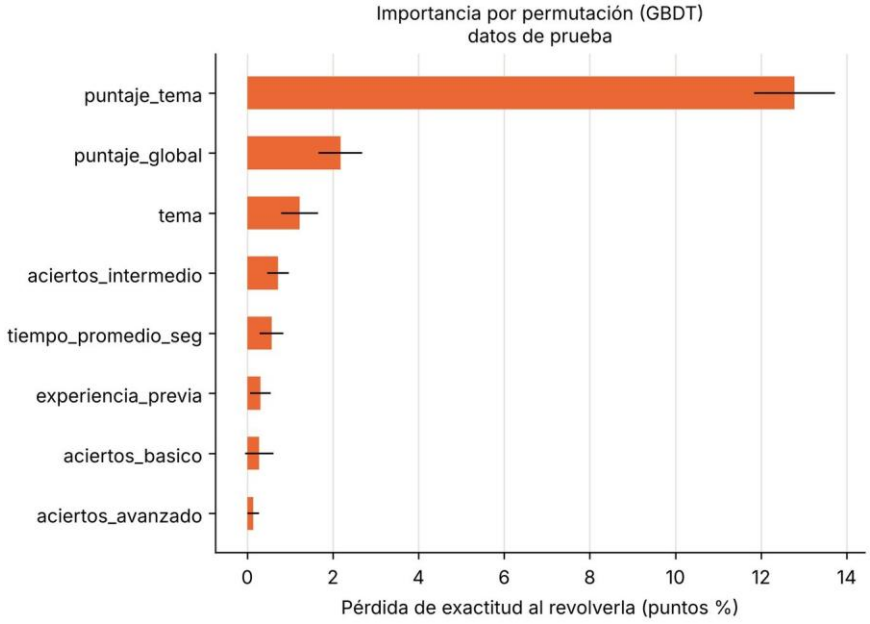


Figura 8. Importancia por permutación del GBDT: si se revuelve puntaje_tema el modelo pierde casi 13 puntos de exactitud; puntaje_global unos 2; tema algo más de 1; las demás menos de 1. Coincide con el análisis de la sección 2.

7. Dónde se ejecuta el modelo y cómo conseguirlo

El profesor pidió desacoplar la IA de la app y que el modelo corra localmente en el celular a partir de un solo archivo. El recorrido es este:

- **1. Entrenar (en el computador, una vez).** src/entrenar_modelo_final.py entrena el GBDT con las 7.500 filas.
- **2. Exportar.** El modelo se guarda en un solo archivo: modelo/cybermind_gbdt.onnx, de unos 106 KB.
- **3. Empaquetar.** El .onnx se copia a app/src/main/assets/ de la app Android.
- **4. Predecir (en el celular, en cada diagnóstico).** ONNX Runtime para Android ejecuta el modelo sin internet.
- **5. Mostrar.** La app muestra la decisión de cada estudiante y tema, con un detalle por estudiante. Los resultados se mantienen solo en memoria.

Por qué ONNX. Un archivo .pkl solo lo abre Python, y en el celular no hay Python. ONNX es un formato abierto que ONNX Runtime ejecuta en Android (y también en iOS, Flutter y React Native).

Aspecto	Detalle	Para qué
Archivo	modelo/cybermind_gbdt.onnx, unos 106 KB	Un solo archivo que se copia a la app
Entradas	Las 8 variables con forma [1, 1]: tema y experiencia_previa como texto; las 6 numéricas como float32, sin escalar	Los mismos nombres de columna del dataset
Salidas	label (1 = REFUERZO, 0 = AVANCE) y probabilities = [prob. AVANCE, prob. REFUERZO]	La probabilidad se usa para decidir y mostrarla
Umbral	REFUERZO si la probabilidad de REFUERZO es 0,5 o más	Se puede subir para ser más prudente
Regla de respaldo	REFUERZO si puntaje_tema es menor a 70	Si el modelo no carga, la app sigue funcionando
Verificación	7.500 de 7.500 decisiones iguales a las de scikit-learn; probabilidades con diferencia menor a 0,000001	El celular decide igual que Python

Cómo conseguirlo. El archivo se descarga del repositorio https://github.com/CyberMind-UNI/CyberMind-ML, en la carpeta modelo/. Para generarlo de nuevo: pip install skl2onnx onnxruntime; python src/entrenar_modelo_final.py; y para probarlo como lo usa la app, solo con ONNX Runtime: python src/probar_modelo_onnx.py.

Desacoplado. Para mejorar la IA se reentrena en Python y solo se reemplaza el .onnx; el código de la app no cambia. El archivo guarda dentro su versión, el umbral y los valores válidos de tema y experiencia_previa.

8. Integración en la app

La app es Android nativa, en Kotlin con Jetpack Compose y Material 3, y usa Supabase (Postgres, autenticación y almacenamiento) como backend. La clase CyberMindModelo carga el .onnx desde assets, arma las 8 entradas del diagnóstico y devuelve la decisión con su probabilidad:

```
val modelo = CyberMindModelo(context)      // carga assets/cybermind_gbdt.onnx
val d = Diagnostico("criptografia", "cursos", 3, 1, 0, 44.4f, 61.0f, 38f)
val decision = modelo.decidir(d)           // se ejecuta en el celular, sin red
```

Ejemplo. Un estudiante con experiencia previa en cursos sacó 44,4 % en criptografía (3 aciertos básicos, 1 intermedio y 0 avanzados), 61 % de puntaje global y 38 segundos por pregunta. El GBDT da REFUERZO con probabilidad 0,90.

Lo que se ve en la app. El módulo «Prepárate con CyberMind» recibe los resultados por archivo CSV (hasta 100 estudiantes) o por ingreso manual, evalúa cada estudiante y tema con este modelo y muestra AVANCE o REFUERZO en una lista y en un detalle por estudiante. Los resultados quedan solo en memoria; guardarlos en Supabase es un paso posterior.

Si el modelo no carga. La app aplica la regla de respaldo: REFUERZO si puntaje_tema es menor a 70.

9. Repositorios y reproducibilidad

Repositorio	Contenido	Enlace
CyberMind-ML	Dataset sintético, scripts y notebooks de las fases 1 a 3, gráficas, modelo .onnx y esta documentación	https://github.com/CyberMind-UNI/CyberMind-ML
nightwatch-protocol	App Android (Kotlin + Jetpack Compose + Supabase) con el modelo integrado	https://github.com/sotelocaronicolas-eng/nightwatch-protocol

Todo usa semilla fija y únicamente cybermind_sintetico.csv, así que cualquier resultado de este documento se puede repetir.

10. Conclusiones y límites

- La IA toma una decisión clara y verificable: REFUERZO o AVANCE después del diagnóstico de un tema.
- Los cuatro modelos no sobreajustan y quedan empatados en exactitud (81,8 % a 83,0 % en prueba), unos 14 a 15 puntos por encima de la línea base.
- Se eligió GBDT por un criterio medible: la calidad de su probabilidad (mejor log loss en 30 de 30 divisiones).
- El modelo corre dentro del celular, sin internet, y da las mismas decisiones que en Python.
- **Límite principal:** los datos son sintéticos. Falta validar con estudiantes reales, medir el efecto pedagógico del refuerzo y guardar los resultados (hoy solo en memoria). Después: seguir el conocimiento de cada estudiante en el tiempo (knowledge tracing).

11. Referencias

- B. S. Bloom, “The 2 Sigma Problem: The Search for Methods of Group Instruction as Effective as One-to-One Tutoring,” Educational Researcher, vol. 13, no. 6, pp. 4–16, 1984.
- J. Kruger y D. Dunning, “Unskilled and Unaware of It: How Difficulties in Recognizing One’s Own Incompetence Lead to Inflated Self-Assessments,” Journal of Personality and Social Psychology, vol. 77, no. 6, pp. 1121–1134, 1999.
- J. H. Friedman, “Greedy Function Approximation: A Gradient Boosting Machine,” Annals of Statistics, vol. 29, no. 5, pp. 1189–1232, 2001.
- F. Pedregosa et al., “Scikit-learn: Machine Learning in Python,” Journal of Machine Learning Research, vol. 12, pp. 2825–2830, 2011.
- ONNX Runtime, Microsoft. [En línea]. Disponible: https://onnxruntime.ai